Medición y diseño de investigación

Clase 2: Manipulación de datos

FCS-UdelaR - Martín Opertti y Fabricio Carneiro

June 26, 2023

Directorios de trabajo

Directorios de trabajo

- Para abrir en R un archivo guardado en tu computadora, debes especificar en qué carpeta está guardado. Hay muchas opciones, una de ellas es fijar un directorio por defecto (es decir, especificarle a R la carpeta en la que vamos a trabajar):

```
# Puedo fijar el directorio de trabajo con la función setwd()
# Fijar la carpeta donde vamos a importar y exportar los archivos:
setwd("micompu/micarpeta")
getwd() # Con está función puedo consultar el directorio
```

```
# Ahora, si quiero leer un archivo que esté en "micompu/micarpeta" simplemente
# escribo su nombre dentro de la función, en el lugar del "path".

# Supongamos que tengo dentro de la carpeta "micarpeta" un excel con datos
# de desempleo en Uruguay:

library(readxl)
desempleo_uru <- read_excel("data/desempleo.xlsx")
head(desempleo_uru, 4)
```

```
## # A tibble: 4 × 2
##    Year  tasa
##   <dbl> <dbl>
## 1  1990   8.5
## 2  1991   8.9
## 3  1992   9
## 4  1993   8.3
```

Crear una carpeta

En la computadora en la que estés trabajando debes crear una carpeta (dentro de la carpeta que prefieras o en el escritorio), con las siguientes carpetas dentro:

- **Data** Descargar de EVA la carpeta data dentro de la sección laboratorio y pegar el contenido aquí.
- **Scripts** Descargar los distintos scripts (archivos de código) del EVA y guardarlos en esta carpeta (código de la clase, ejercicios, etc.)
- **graficos** Crear una carpeta gráficos que por el momento esté vacía, vamos a ir incluyendo guardando archivos ahí
- **resultados** Crear una carpeta resultados que por el momento esté vacía, vamos a ir incluyendo guardando archivos ahí

Carpeta del curso

Deberían ver en su carpeta algo así:

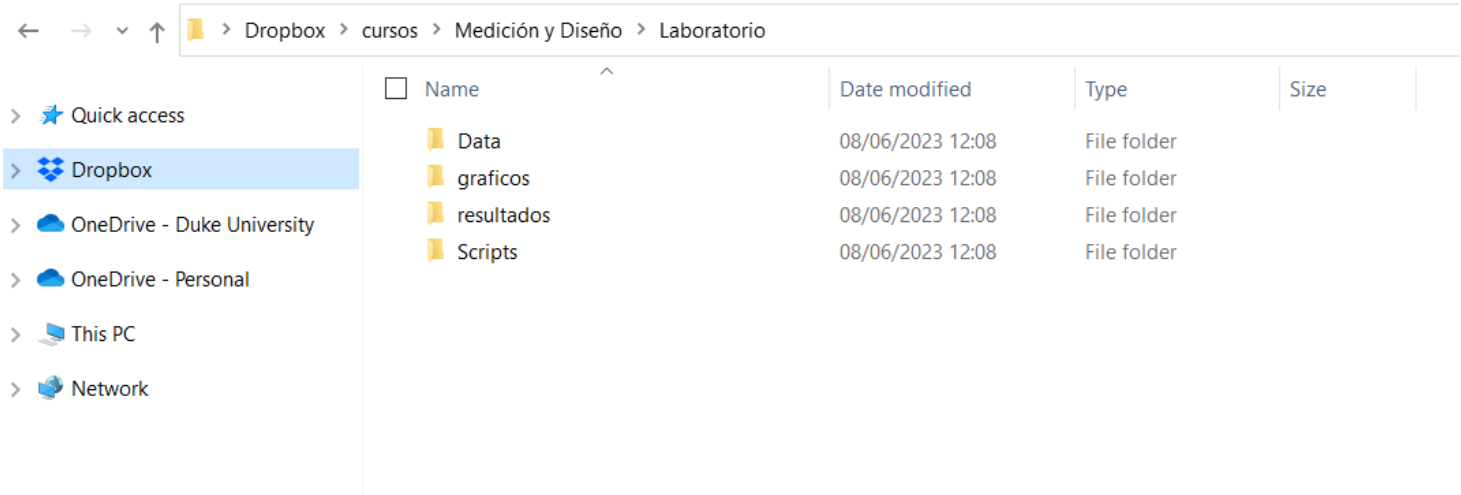

Directorio de R

Al comienzo de cada script **deben** especificar el directorio donde está su carpeta del curso, de lo contrario los códigos les van a devolver errores.

En este caso, por ejemplo, creé la carpeta "cacrpeta_del_curso" dentro de una carpeta llamada "Medicion y diseño" dentro de "cursos". Para acceder al directorio completo vayan a donde esta su carpeta hagan click derecho en la carpeta, seleccionen "propiedades" y luego ahí bajo dirección pueden copiar el directorio.

```
setwd("C:/Usuario/Martin/Dropbox/cursos/Medicion y diseño/cacrpeta_del_curso")
```

De esta forma, por ejemplo, si queremos leer una base de datos llamada "datauru.xlsx" que está guardada en la carpeta data dentro de la carpeta laboratorio, simplemente tenemos que especificar la siguiente dirección (porque R ya lo va a buscar dentro de la carpeta laboratorio)

```
datauru <- read_excel("data/datauru.xlsx")
```

Importar y exportar datos

Importar datos

- Hasta ahora trabajamos principalmente con datos ingresados manualmente con las funciones `c()` y `data.frame()`
- Normalmente cuando trabajamos con datos solemos utilizar datos ya creados guardados en los formatos de otros programas (ej. Excel, Stata, SPSS)
- Existen varios paquetes que permiten importar y exportar datos desde distintos formatos. Algunos de los más utilizados son readr, haven, readxl y utils
- El primer paso es siempre identificar la extensión del archivo que queremos importar. Por ejemplo, las planillas excel (dependiendo de la versión) suelen tener extension .xlsx. Pueden consultar la extensión de un archivo con botón derecho + propiedades
- Luego deben identificar en qué carpeta está guardada esa base de datos.

Importar datos

Distintas funciones nos sirven para importar datos a R desde distintos formatos. Veamos algunos ejemplos:

```
# Con la función read_csv() del paquete readr importamos archivos .csv
library(tidyverse)
gapminder_csv <- read_csv("data/gapminder.csv")

# Con la función read_excel() del paquete readxl importamos archivos excel
library(readxl)
gapminder_excel <- read_excel("data/gapminder.xlsx")
```

```
# Vemos que los dataframes son iguales, tienen la mismas filas y columnas
dim(gapminder_csv)
```

```
## [1] 1704    6
```

```
dim(gapminder_excel)
```

```
## [1] 1704    6
```

Importar datos

Algunos paquetes incluyen datos, por ejemplo, gapminder. En la documentación del paquete se encuentra el nombre de los datos. Con una simple asignación los podemos cargar

```
#install.packages("gampminder")
library(gapminder)

data_gapminder <- gapminder
head(data_gapminder)
```

```
## # A tibble: 6 × 6
##   country     continent  year lifeExp      pop gdpPercap
##   <fct>       <fct>     <int>   <dbl>    <int>     <dbl>
## 1 Afghanistan Asia       1952    28.8  8425333      779.
## 2 Afghanistan Asia       1957    30.3  9240934      821.
## 3 Afghanistan Asia       1962    32.0 10267083      853.
## 4 Afghanistan Asia       1967    34.0 11537966      836.
## 5 Afghanistan Asia       1972    36.1 13079460      740.
## 6 Afghanistan Asia       1977    38.4 14880372      786.
```

Importar datos

También es posible importar datos guardados en los formatos de otros softwares estadísticos como SPSS o Stata. Para esto usaremos el paquete haven.

```
library(haven)

# SPSS
gapminder_spss <- read_spss("data/gapminder.sav")

# STATA
gapminder_stata <- read_stata("data/gapminder.dta")
```

O podríamos llamar a la función y paquete dado que generalmente solo utilizamos una función de los paquetes que cargan datos (depende del caso obviamente)

```
# SPSS
gapminder_spss <- haven::read_spss("data/gapminder.sav")

# STATA
gapminder_stata <- haven::read_stata("data/gapminder.dta")
```

Importar datos

R también cuenta con sus propios formatos de almacenamiento de datos (`.rds` y `.Rdata` o `.rda`). Este enfoque es poco práctico si queremos usar los datos almacenados en otro programa, pero muy útil si solamente usaremos R dado que mantiene la información tal cual estaba en R (por ej. tipos de variables o atributos):

```
# Para esto no necesitamos cargar paquetes.
# Guardar un objeto como .rds:
saveRDS(object = data_gapminder,
        file = "resultados/data_gapminder.rds")

 # Leemos un archivo .rds
miobjeto_rds <- readRDS(file = "resultados/data_gapminder.rds")

# Con .rda se pueden guardar varios objetos al mismo tiempo!
# Exportamos un archivo .Rdata
save(data_gapminder, miobjeto_rds,
     file = "resultados/dos_dataframes.Rdata")

 # Importamos un archivo .Rdata
load("resultados/dos_dataframes.Rdata")
```

Exportar datos

- También podemos guardar archivos desde R en otros formatos.
- Con readr podemos exportar archivos en formato .csv
- Con writexl podemos exportar directamente un excel.
- Con haven podemos exportar achivos en formato .dta (Stata) y .sav (SPSS)

```
# Guardar .csv
library(gapminder)
data_gapminder <- gapminder
write_excel_csv(data_gapminder, "resultados/gapminder.csv")

# Guardar excel
library(writexl)
write_xlsx(data_gapminder, "resultados/gapminder.xlsx")

# Guardar .dta (Stata)
library(haven)
write_dta(data_gapminder, "resultados/gapminder.dta")

# Guardar .sav (SPSS)
write_sav(data_gapminder, "resultados/gapminder.sav")

# Guardar .sas (SAS)
write_sas(data_gapminder, "resultados/gapminder.sas")
```

Etiquetas cuando importamos datos

- Cuando importamos datos que tienen etiquetas (por ejemplo de formatos como Stata o SPSS) debemos tener cuidado con cómo manejar estas etiquetas
- Por ejemplo, supongamos que queremos leer los datos de una encuesta con dos variables, guardada en formato Stata (`.dta`), con el paquete `haven`:

```
data <- haven::read_stata("data/ej_encuesta.dta")
head(data, 5)
```

```
## # A tibble: 5 × 2
##   P1              P14
##   <dbl+lbl>       <dbl+lbl>
## 1  4 [Colonia]    1 [Muy mala]
## 2 18 [Tacuarembó] 2 [Mala]
## 3 15 [Salto]      5 [Muy buena]
## 4  1 [Artigas]    3 [Ni buena ni mala]
## 5 10 [Montevideo] 1 [Muy mala]
```

- Por defecto se leen como variables de tipo `double` (numérica) con etiquetas como atributos

Etiquetas cuando importamos datos

Si queremos quedarnos directamente coon las etiquetas, podemos utilizar la funcion `as_factor`:

```
data <- haven::read_stata("data/ej_encuesta.dta") %>%
  as_factor()
head(data, 5)
```

```
## # A tibble: 5 × 2
##   P1          P14
##   <fct>       <fct>
## 1 Colonia     Muy mala
## 2 Tacuarembó  Mala
## 3 Salto       Muy buena
## 4 Artigas     Ni buena ni mala
## 5 Montevideo  Muy mala
```

Importar y exportar datos: factores

- Otro tipo de variables en R son los factores (factors), utilizados para representar data categórica. Estos suelen confundirse con las variables de caracteres pero tienen algunas diferencias.
- Normalmente los factores son utilizados para las variables de caracteres con un número de valores posibles fijo y cierto orden (opcional)
- A R le gusta transformar las variables de caracteres en factores al importarlas (si usamos R Base particularmente).
- El paquete forcats (dentro del Tidyverse) ayuda a manejar variables de caracteres y factores:
  - `fct_relevel()` cambia manualmente el orden de los niveles
  - `fct_reoder()` cambia el orden de los niveles de acuerdo a otra variable
  - `fct_infreq()` reordena un factor por la frecuencia de sus valores
  - `fct_lump()` collapsa los valores menos frecuentes en otra categoría "other". Es muy útil para preparar datos para tablas y gráficos

Importar y exportar datos: factores

```
# Podemos chequear y coercionar factores
data_gapminder <- gapminder
is.factor(data_gapminder$continent) # Chequeo si es factor
```

```
## [1] TRUE
```

```
levels(data_gapminder$continent) # Chequeo los niveles
```

```
## [1] "Africa"   "Americas" "Asia"     "Europe"   "Oceania"
```

```
# Transformo a caracter
data_gapminder$continent <- as.character(data_gapminder$continent)
class(data_gapminder$continent)
```

```
## [1] "character"
```

```
# De vuelta a factor
data_gapminder$continent <- as.factor(data_gapminder$continent)
class(data_gapminder$continent)
```

```
## [1] "factor"
```

Explorar Dataframes

Resumen de un dataframe

```
dim(data_gapminder) # Número de filas y columnas
```

```
## [1] 1704    6
```

```
names(data_gapminder) # Nombre de variables
```

```
## [1] "country"   "continent" "year"      "lifeExp"   "pop"       "gdpPercap"
```

```
head(data_gapminder, 3) # Imprime primeras filas (3 en este caso)
```

```
## # A tibble: 3 × 6
##   country     continent  year lifeExp      pop gdpPercap
##   <fct>       <fct>     <int>   <dbl>    <int>     <dbl>
## 1 Afghanistan Asia       1952    28.8  8425333      779.
## 2 Afghanistan Asia       1957    30.3  9240934      821.
## 3 Afghanistan Asia       1962    32.0 10267083      853.
```

Resumen de un dataframe

Una de las funciones más utiles para resumir un dataframe es `glimpse()` del paquete dplyr o tidyverse. Es particularmente util debido a que permite un vistazo al nombre, tipo y primeros valores de **todos** las variables de un dataframe.

```
# Resumen más completo:
glimpse(gapminder)
```

```
## Rows: 1,704
## Columns: 6
## $ country   <fct> "Afghanistan", "Afghanistan", "Afghanistan", "Afghanistan", …
## $ continent <fct> Asia, Asia, Asia, Asia, Asia, Asia, Asia, Asia, Asia, Asia, …
## $ year      <int> 1952, 1957, 1962, 1967, 1972, 1977, 1982, 1987, 1992, 1997, …
## $ lifeExp   <dbl> 28.801, 30.332, 31.997, 34.020, 36.088, 38.438, 39.854, 40.8…
## $ pop       <int> 8425333, 9240934, 10267083, 11537966, 13079460, 14880372, 12…
## $ gdpPercap <dbl> 779.4453, 820.8530, 853.1007, 836.1971, 739.9811, 786.1134, …
```

Tablas simples

En R Base la función para obtener frecuencias es `table()` junto con `prop.table()` y `addmargins()`

```
# Para obtener una tabla de frecuencias de una variable usamos la función
# table() de R Base
tabla_1 <- table(data_gapminder$continent) # Frecuencia simple
tabla_1
```

```
##
##   Africa Americas     Asia   Europe  Oceania
##      624      300      396      360       24
```

```
prop.table(tabla_1) # Proporciones
```

```
##
##     Africa   Americas       Asia     Europe    Oceania
## 0.36619718 0.17605634 0.23239437 0.21126761 0.01408451
```

```
addmargins(tabla_1) # Totales
```

```
##
##   Africa Americas     Asia   Europe  Oceania      Sum
##      624      300      396      360       24     1704
```

```
addmargins(prop.table(tabla_1)) # Proporciones y totales
```

```
##
##     Africa   Americas       Asia     Europe    Oceania        Sum
## 0.36619718 0.17605634 0.23239437 0.21126761 0.01408451 1.00000000
```

Estadística descriptiva

Medidas de tendencia central

```
mean(data_gapminder$lifeExp) # Media
```

```
## [1] 59.47444
```

```
median(data_gapminder$lifeExp) # Mediana
```

```
## [1] 60.7125
```

```
sd(data_gapminder$lifeExp) # Desvío estandar
```

```
## [1] 12.91711
```

Rangos

```
range(data_gapminder$lifeExp) # Rango
```

```
## [1] 23.599 82.603
```

```
max(data_gapminder$lifeExp)
```

```
## [1] 82.603
```

```
min(data_gapminder$lifeExp)
```

```
## [1] 23.599
```

Histogramas

También podemos graficar los datos rápidamente. Por ejemplo, un histograma:

```
hist(data_gapminder$lifeExp,
     main = "Distribución de expectativa de vida (Gapminder)")
```

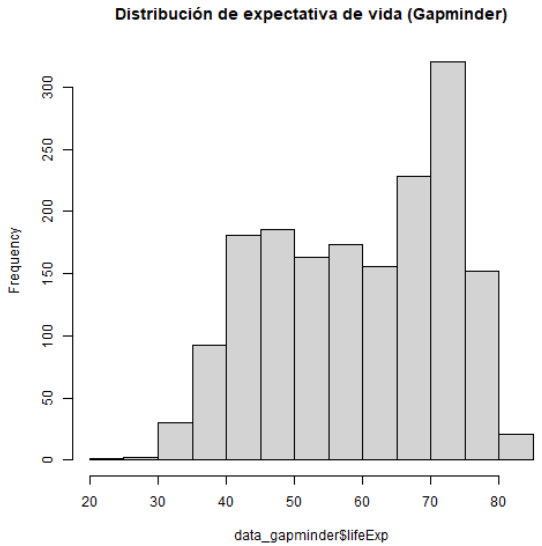

Gráfico de dispersión (scatterplot)

```
plot(data_gapminder$lifeExp, data_gapminder$gdpPercap,
main = "Relación entre expectativa de vida y PBI per cápita")
```

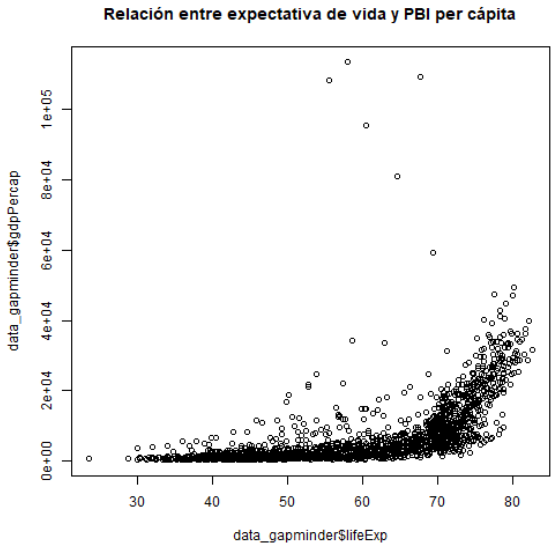

Ejercicio

(1) Importar el archivo excel en la carpeta data llamado "datauru"

(2) Explorar las variables y el tipo de cada variable con la función glimpse()

(3) Calcular la media de una variable numérica

(4) Crear una tabla de proporciones con la distribución de la variable partido

(5) Crear un gráfico de dispersión con las variables inflación (eje de las x) y aprobación (eje de las y)

Transformar datos

Transformar datos con dplyr

El paquete dplyr contiene funciones muy útiles para la transformación de dataframes (tibbles). Todas las funciones tienen en común que su primer argumento es un dataframe y que devuelven un dataframe. Algunas de las funciones que vamos a ver:

- `filter()`: filtrar observaciones en base a valores
- `select()`: filtrar variables
- `mutate()`: crear o recodificar variables
- `group_by()`: define grupos de valores utilizar las otras funciones
- `summarise()`: colapsa valores según alguna fórmula (sumar, número de casos, media, etc.)

Filtrar

Una de las tareas más comunes en el análisis de datos es filtrar observaciones en base a condiciones. Existen muchas maneras de filtrar datos en R, la función `filter()` de dplyr es una de las más sencillas de utilizar. El primer argumento es el dataframe y el segundo la condición por la que queremos filtrar.

```
# Tenemos datos de muchos años:
table(gapminder$year)
```

```
##
## 1952 1957 1962 1967 1972 1977 1982 1987 1992 1997 2002 2007
##  142  142  142  142  142  142  142  142  142  142  142  142
```

```
# Filtremos para con los datos a partir de 2007
gapminder_07 <- filter(gapminder, year == 2007)
table(gapminder_07$year)
```

```
##
## 2007
##  142
```

Filtrar

Utilizando operadores lógicos podemos filtrar de formas más complejas:

```
# Todas los años menos 2007
gapminder_pre07 <- filter(gapminder, year != 2007)
table(gapminder_pre07$year)
```

```
##
## 1952 1957 1962 1967 1972 1977 1982 1987 1992 1997 2002
##  142  142  142  142  142  142  142  142  142  142  142
```

```
# Solo los siguientes años: 1952, 1992 y 2007
anios_especificos <- c(1952, 1992, 2007)
gapminder_esp <- filter(gapminder, year %in% anios_especificos)

table(gapminder_esp$year)
```

```
##
## 1952 1992 2007
##  142  142  142
```

Seleccionar variables

Con `select()` podemos seleccionar las variables (columnas) que queremos mantener en un dataframe. Podemos nombrarlas, seleccionar cuáles queremos eliminar y referirnos por su orden:

```
# Selccionar un conjunto de variables (país, año, población)
select(gapminder, country, year, pop)

# Selccionar todas las variables menos las especificadas
select(gapminder, -continent)

# Seleccionar un rango de variables según orden
select(gapminder, country:lifeExp)
select(gapminder, 1:3) # Orden numérico
```

Pipeline %>%

Cuando queremos realizar más de una operación a un dataframe podemos utilizar el pipeline. Como vimos, la mayoría de las funciones de dplyr que se aplican a un dataframe tienen como primer argumento el dataframe al que le queremos aplicar la función.

Con el pipeline especificamos el dataframe solamente una vez al principio, y luego todas las funciones que vamos utilizando no necesitan especificación. De esta forma nos enfocamos en la transformación y no en el objeto.

```
gapminder_07_america <- gapminder %>%
  filter(year == 2007 & continent == "Americas") %>%
  select(-continent)

print(gapminder_07_america)
```

```
## # A tibble: 25 × 5
##    country             year lifeExp       pop gdpPercap
##    <fct>              <int>   <dbl>     <int>     <dbl>
##  1 Argentina           2007    75.3  40301927    12779.
##  2 Bolivia             2007    65.6   9119152     3822.
##  3 Brazil              2007    72.4 190010647     9066.
##  4 Canada              2007    80.7  33390141    36319.
##  5 Chile               2007    78.6  16284741    13172.
##  6 Colombia            2007    72.9  44227550     7007.
##  7 Costa Rica          2007    78.8   4133884     9645.
##  8 Cuba                2007    78.3  11416987     8948.
##  9 Dominican Republic  2007    72.2   9319622     6025.
## 10 Ecuador             2007    75.0  13755680     6873.
## # … with 15 more rows
```

Pipeline %>%

- Una de las ventajas del Tidyverse es la facilidad con la que se puede leer e interpretar el código. Un elemento fundamental para esto es el pipeline (`%>%`). Es muy útil para expresar una secuencia de muchas operaciones.
- Habíamos visto varias formas de realizar esto: sobrescribir el mismo objeto, con objetos intermedios o anidando funciones.
- El pipeline del paquete magrittr hace más fácil modificar operaciones puntuales dentro de conjunto de operaciones, hace que sea más fácil leer (evitando leer de adentro hacia afuera) entre otras ventajas.
- Es recomendable evitar usar el pipeline cuando queremos trabajar más de un objeto a la vez
- `x %>% f == f(x)`
- Se puede leer como un "y entonces"

Otras funciones de dplyr muy útiles

- `arrange()` ordenar los datos según una o más variables
- `rename()` cambiar el nombre de las variables de un dataframe
- `pull()` y `distinct()`: con `distinct()` es posible identificar los valores distintos de una variable y con `pull()` los podemos extraer como un vector
- `slice_min()` y `slice_max()`: filtrar n observaciones de mayor o menor valor según variable. En general, la familia de funciones slice permite filtrar observaciones en función de su posición.
- `count()` contar observaciones por grupo
- `relocate()` cambiar el orden de columnas

Crear y recodificar variables

Crear variables con mutate()

El paquete dplyr contiene la función `mutate()` para crear nuevas variables. `mutate()` crea variables al final del dataframe.

```
data_gapminder <- gapminder

# Variable de caracteres
data_gapminder <- mutate(data_gapminder, var1 = "Valor fijo")

# Variable numérica
data_gapminder <- mutate(data_gapminder, var2 = 7)
head(data_gapminder, 3)
```

```
## # A tibble: 3 × 8
##   country     continent  year lifeExp      pop gdpPercap var1        var2
##   <fct>       <fct>     <int>   <dbl>    <int>     <dbl> <chr>      <dbl>
## 1 Afghanistan Asia       1952    28.8  8425333      779. Valor fijo     7
## 2 Afghanistan Asia       1957    30.3  9240934      821. Valor fijo     7
## 3 Afghanistan Asia       1962    32.0 10267083      853. Valor fijo     7
```

```
## Podemos escribir lo mismo de distinta manera:
data_gapminder <- mutate(data_gapminder, var1 = "Valor fijo",
                                         var2 = 7)
```

Recodificar variables con mutate()

Con `mutate()` también podemos realizar operaciones sobre variables ya existentes:

```
## Podemos recodificar usando variables y operadores aritméticos
# Calculemos el pbi total (pbi per capita * población)
d_gap <- mutate(gapminder, gdp = gdpPercap * pop)
head(d_gap, 3)
```

```
## # A tibble: 3 × 7
##   country     continent  year lifeExp      pop gdpPercap         gdp
##   <fct>       <fct>     <int>   <dbl>    <int>     <dbl>       <dbl>
## 1 Afghanistan Asia       1952    28.8  8425333      779. 6567086330.
## 2 Afghanistan Asia       1957    30.3  9240934      821. 7585448670.
## 3 Afghanistan Asia       1962    32.0 10267083      853. 8758855797.
```

```
# Podemos calcular el logaritmo
d_gap <- mutate(d_gap, gdp_log = log(gdp))
head(d_gap, 2)
```

```
## # A tibble: 2 × 8
##   country     continent  year lifeExp     pop gdpPercap         gdp gdp_log
##   <fct>       <fct>     <int>   <dbl>   <int>     <dbl>       <dbl>   <dbl>
## 1 Afghanistan Asia       1952    28.8 8425333      779. 6567086330.    22.6
## 2 Afghanistan Asia       1957    30.3 9240934      821. 7585448670.    22.7
```

Transformaciones de tipo

Al igual que hacíamos con los vectores, podemos tranformar el tipo de una variable

```
# Exploro tipo de variables
glimpse(d_gap)
```

```
## Rows: 1,704
## Columns: 3
## $ continent <fct> Asia, Asia, Asia, Asia, Asia, Asia, Asia, Asia, Asia, Asia, …
## $ year      <int> 1952, 1957, 1962, 1967, 1972, 1977, 1982, 1987, 1992, 1997, …
## $ lifeExp   <dbl> 28.801, 30.332, 31.997, 34.020, 36.088, 38.438, 39.854, 40.8…
```

```
# Variable continente a caracteres y año a factor
d_gap <- d_gap %>%
  mutate(continent = as.character(continent),
         year = as.factor(year))

glimpse(d_gap)
```

```
## Rows: 1,704
## Columns: 3
## $ continent <chr> "Asia", "Asia", "Asia", "Asia", "Asia", "Asia", "Asia", "Asi…
## $ year      <fct> 1952, 1957, 1962, 1967, 1972, 1977, 1982, 1987, 1992, 1997, …
## $ lifeExp   <dbl> 28.801, 30.332, 31.997, 34.020, 36.088, 38.438, 39.854, 40.8…
```

Recodificaciones condicionales

Recodificaciones condicionales

- Muchas veces transformar los datos implica recodificar una variable de forma condicional, esto es, asignar distintos valores en función de los valores de una o más variables.
- Para esto podemos utilizar las funciones; ifelse() (R Base), mutate(), recode() y case_when() (Tidyverse)
- Nosotros veremos recodificaciones condicionales con `case_when()` y `mutate()`

Recodificación condicional con case_when y mutate

Podemos crear variables condicionales con `case_when()` del paquete dplyr. Esencialmente, con `ifelse()` (R Base) podemos lograr lo mismo que con `case_when()` (Tidyverse). `case_when()` puede resultar más sencilla de utilizar al no haber necesidad de anidar la función cuando establecemos múltiples condiciones.

Cuando trabajmos con dataframes `case_when()` se utiliza dentro de `mutate()`. `case_when()` testea condiciones en orden (esto es importante cuando pasamos condiciones no excluyentes). `case_when()` lista condiciones para las que asigna un valor en caso de que sean verdaderas, y permite pasar múltiples condiciones. `TRUE` refiere a las condiciones no listadas. La estructura de `case_when()` es:

```
data %>%
  mutate(var_nueva = case_when(var_original == "Valor 1" ~ "Valor A",
                               var_original == "Valor 2" ~ "Valor B",
                               TRUE ~ "Otros"))
```

Recodificación condicional con case_when y mutate

```
d_gap <- gapminder

# Creemos una variable que indique si el país es Uruguay o no
d_gap <- d_gap %>%
  mutate(uruono = case_when(
    country == "Uruguay" ~ "Si",
    TRUE ~ "No")
    )

table(d_gap$uruono)
```

```
##
##   No   Si
## 1692   12
```

Recodificación condicional con case_when y mutate

Podemos establecer varias condiciones fácilmente:

```
d_gap <- gapminder

d_gap <- d_gap %>%
  mutate(mercosur = case_when(country == "Uruguay" ~ 1,
                              country == "Argentina" ~ 1,
                              country == "Paraguay" ~ 1,
                              country == "Brazil" ~ 1,
                              TRUE ~ 0))

table(d_gap$mercosur)
```

```
##
##    0    1
## 1656   48
```

Recodificación condicional con case_when y mutate

También podríamos usar operadores para simplificar esto:

```
d_gap <- d_gap %>%
  mutate(mercosur = case_when(
  country %in% c("Argentina", "Paraguay", "Brazil", "Uruguay") ~ 1,
  TRUE ~ 0)
  )

d_gap <- d_gap %>%
  mutate(mercosur2 = case_when(
    country == "Argentina" | country == "Paraguay" |
      country == "Brazil" | country == "Uruguay" ~ 1,
    TRUE ~ 0)
    )

identical(d_gap$mercosur, d_gap$mercosur2)
```

```
## [1] TRUE
```

Recodificación condicional con case_when y mutate

Recodificación con valores numéricos. Supongamos que queremos crear una nueva variable pob_rec, que clasifica a los países en población grande (más de 20 millones), mediana (entre 5 y 20) o pequeña (menos de 5)

```
d_gap <- d_gap %>%
  mutate(pob_rec = case_when(
    pop >= 20000000 ~ "Grande",
    pop >= 5000000 & pop < 20000000 ~ "Mediana",
    pop < 5000000 ~ "Pequeña",
    TRUE ~ "Error")
  )

table(d_gap$pob_rec)
```

```
##
##  Grande Mediana Pequeña
##     419     580     705
```

Recodificación condicional con case_when y mutate

`case_when()` sirve también para recodificar una variable con condiciones basadas en múltiples variables.

Supongamos que queremos una variable que indique los países-año con expectativa de vida mayor a 75 o pbi per cápita mayor a 20.000

```
d_gap <- d_gap %>%
  mutate(var1 = case_when(gdpPercap > 20000 ~ 1,
                          lifeExp > 75 ~ 1,
                          TRUE ~ 0))
table(d_gap$var1)
```

```
##
##    0    1
## 1493  211
```

Resumenes y tablas

Resumir datos: tablas simples

Con `count()` podemos hacer lo mismo que con `table()`, pero en el contexto del tidyverse. Con un simple `mutate()` podemos transformar la frecuencia simple en proporción o porcentaje

```
# Frecuencia simple
d_gap %>%
  count(continent)
```

```
## # A tibble: 5 × 2
##   continent     n
##   <fct>     <int>
## 1 Africa      624
## 2 Americas    300
## 3 Asia        396
## 4 Europe      360
## 5 Oceania      24
```

```
# Frecuencia proporción
d_gap %>%
  count(continent) %>%
  mutate(per = n/sum(n)*100) %>% # Porcentaje
  mutate(prop = n/sum(n)) # Proporción
```

```
## # A tibble: 5 × 4
##   continent     n   per   prop
##   <fct>     <int> <dbl>  <dbl>
## 1 Africa      624 36.6  0.366
## 2 Americas    300 17.6  0.176
## 3 Asia        396 23.2  0.232
## 4 Europe      360 21.1  0.211
## 5 Oceania      24  1.41 0.0141
```

Resumir datos: tablas cruzadas

Cuando usamos `count()` con dos variables vemos que la salida está en formato largo. Eso nos puede servir para graficar si usamos ggplot2 y para otros paquetes, pero no es como generalmente queremos leer una tabla para interpretarla.

```
# Tabla cruzada en formato largo
d_gap %>%
  count(continent, pob_rec)
```

```
## # A tibble: 15 × 3
##    continent pob_rec     n
##    <fct>     <chr>   <int>
##  1 Africa    Grande     86
##  2 Africa    Mediana   208
##  3 Africa    Pequeña   330
##  4 Americas  Grande     72
##  5 Americas  Mediana    98
##  6 Americas  Pequeña   130
##  7 Asia      Grande    168
##  8 Asia      Mediana   111
##  9 Asia      Pequeña   117
## 10 Europe    Grande     92
## 11 Europe    Mediana   152
## 12 Europe    Pequeña   116
## 13 Oceania   Grande      1
## 14 Oceania   Mediana    11
## 15 Oceania   Pequeña    12
```

Resumir datos: tablas cruzadas

Para pasar a formato ancho podemos utilizar la función `spread()`. El primer argumento dentro de `spread()` es la variable que queremos que pase a ser columnas y el segundo argumento la variable que contiene los valores.

```
# Tabla cruzada en formato ancho
d_gap %>%
  count(continent, pob_rec) %>%
  spread(pob_rec, n)
```

```
## # A tibble: 5 × 4
##   continent Grande Mediana Pequeña
##   <fct>      <int>   <int>   <int>
## 1 Africa        86     208     330
## 2 Americas      72      98     130
## 3 Asia         168     111     117
## 4 Europe        92     152     116
## 5 Oceania        1      11      12
```

Resumir datos: tablas cruzadas

Cuando analizamos tablas cruzadas, muchas veces queremos ver procentajes en lugar de frecuencias. Para ello podemos transformar la frecuencia en porcentaje.

```
# Porcentaje total
d_gap %>%
  count(continent, pob_rec) %>%
  mutate(n = n/sum(n)*100) %>%
  spread(pob_rec, n)
```

```
## # A tibble: 5 × 4
##   continent Grande Mediana Pequeña
##   <fct>      <dbl>   <dbl>   <dbl>
## 1 Africa    5.05    12.2    19.4
## 2 Americas  4.23     5.75    7.63
## 3 Asia      9.86     6.51    6.87
## 4 Europe    5.40     8.92    6.81
## 5 Oceania   0.0587   0.646   0.704
```

Resumir datos: tablas cruzada

Cuando trabajamos con procentajes en tablas cruzadas, tenemos que considerar el total del %. En el ejemplo anterior el porcentaje era sobre el total, muchas veces queremos calcularlo sobre cada fila o cada columna

```
# % de paises en cada tamaño de población por continente
d_gap %>%
  count(continent, pob_rec) %>%
  mutate(n = n/sum(n)*100, .by = continent) %>%
  spread(pob_rec, n)
```

```
## # A tibble: 5 × 4
##   continent Grande Mediana Pequeña
##   <fct>      <dbl>   <dbl>   <dbl>
## 1 Africa     13.8     33.3    52.9
## 2 Americas   24       32.7    43.3
## 3 Asia       42.4     28.0    29.5
## 4 Europe     25.6     42.2    32.2
## 5 Oceania     4.17    45.8    50
```

```
# % de continente por tamaño de población
d_gap %>%
  count(continent, pob_rec) %>%
  mutate(n = n/sum(n)*100, .by = pob_rec) %>%
  spread(pob_rec, n)
```

```
## # A tibble: 5 × 4
##   continent Grande Mediana Pequeña
##   <fct>      <dbl>   <dbl>   <dbl>
## 1 Africa    20.5     35.9    46.8
## 2 Americas  17.2     16.9    18.4
## 3 Asia      40.1     19.1    16.6
## 4 Europe    22.0     26.2    16.5
## 5 Oceania    0.239    1.90    1.70
```

Resumir datos

Resumir datos con estadísticos descriptivos es una de las partes fundamentales del análisis de datos. Para ello utilizaremos la función `summarise()` o `summarize()`, muchas veces en conjunto con `group_by()`.

Escencialmente `summarise()` resume un dataframe en una fila según una estadística especificada. Por ejemplo, calculando la media de una variable

```
gapminder %>%
  summarise(media = mean(lifeExp, na.rm=T))
```

```
## # A tibble: 1 × 1
##   media
##   <dbl>
## 1  59.5
```

```
# Por ahora no hay mucha diferencia con
mean(gapminder$lifeExp, na.rm = TRUE)
```

```
## [1] 59.47444
```

Resumir datos

Hasta ahora `summarise()` no nos es de gran utilidad, la utilidad de `summarise()` es su uso conjunto con `group_by()`, para estimar diferentes estadísticas según grupos específicos.

Cuando utilizamos `group_by()` en un pipeline cambiamos la unidad de análisis desde todo el dataframe a niveles de una variable. Retomando el ejemplo, podemos ver el promedio de expectativa de vida según año:

```
gapminder %>%
  group_by(year) %>%
  summarise(media = mean(lifeExp, na.rm = T))
```

```
## # A tibble: 12 × 2
##     year media
##    <int> <dbl>
##  1  1952  49.1
##  2  1957  51.5
##  3  1962  53.6
##  4  1967  55.7
##  5  1972  57.6
##  6  1977  59.6
##  7  1982  61.5
##  8  1987  63.2
##  9  1992  64.2
## 10  1997  65.0
## 11  2002  65.7
## 12  2007  67.0
```

Resumir datos

Algunas de las operaciones más utilizadas para resumir datos:

- `mean()`: media
- `median()`: mediana
- `sd()`: desvío estandar
- `sum()`: suma
- `n()`: número de observaciones
- `n_distinct()`: número de valores únicos
- `min()` y `max()`: mínimo y máximo
- `first()`: primer valor

Resumir datos

Podemos utilizar más de una variable dentro de `group_by()`. Por ejemplo, calculemos la media de expectativa de vida por año comparando America y Europa para 1997, 2002 y 2007:

```
resumen_1 <- gapminder %>%
  filter(continent %in% c("Americas", "Europe")) %>%
  filter(year >= 1997) %>%
  group_by(continent, year) %>%
  summarise(media = mean(lifeExp, na.rm = TRUE))
```

```
## `summarise()` has grouped output by 'continent'. You can override using the
## `.groups` argument.
```

```
resumen_1
```

```
## # A tibble: 6 × 3
## # Groups:   continent [2]
##   continent  year media
##   <fct>     <int> <dbl>
## 1 Americas   1997  71.2
## 2 Americas   2002  72.4
## 3 Americas   2007  73.6
## 4 Europe     1997  75.5
## 5 Europe     2002  76.7
## 6 Europe     2007  77.6
```

Resumir datos

Una de las grandes ventajas de `summarise()` es que podemos resumir muy fácilmente varias estadísticas en un solo dataframe.

```
resumen_2 <- gapminder %>%
  filter(continent %in% c("Americas", "Europe")) %>%
  filter(year == 2007) %>%
  group_by(continent) %>%
  summarise(media = mean(gdpPercap),
            desvio = sd(gdpPercap),
            suma = sum(gdpPercap),
            max = max(gdpPercap),
            min = min(gdpPercap),
            paises = n())

resumen_2
```

```
## # A tibble: 2 × 7
##   continent  media desvio    suma    max   min paises
##   <fct>      <dbl>  <dbl>   <dbl>  <dbl> <dbl>  <int>
## 1 Americas  11003.  9713. 275076. 42952. 1202.     25
## 2 Europe    25054. 11800. 751634. 49357. 5937.     30
```

<!--

--> <!-- -->